FILIÈRE INTELLIGENCE ARTIFICIELLE • OPTION ASSISTANT DATA ANALYST

Module M201

Approfondir les Systèmes Décisionnels

Livret de Synthèse Pédagogique Intégrale & Mémento d'Examen

Enseignant Responsable : **Pr. SADRATI Zakariae**

Année Universitaire & Formation Continue

SOMMAIRE DES 7 SÉANCES DE COURS

- **Séance 01** : Fondements & Mesures Centrales (Moyenne, Médiane, Mode)
- **Séance 02** : Dispersion & Détection Univariée (2-Sigma)
- **Séance 03** : Position, IQR, Règle de Tukey & Box Plots
- **Séance 04** : Standardisation, Normalisation, Isolation Forest & DBSCAN
- **Séance 05** : Probabilités, Théorème de Bayes & Naive Bayes
- **Séance 07** : Vulgarisation du Langage R & RStudio
- **Séance 11** : Visualisation Décisionnelle & Datastorytelling
- **Mémento** : Formules croisées Python, R et Excel

SÉANCE 01

Fondements de la Statistique Décisionnelle & Mesures Centrales

Comprendre le rôle des statistiques dans la prise de décision, maîtriser la typologie des variables et le calcul des mesures de tendance centrale (Moyenne, Médiane, Mode) sous Excel et Python.

POINTS FONDAMENTAUX À RETENIR :

- Différencier clairement Statistique Descriptive (décrire l'existant) et Statistique Inférentielle (généraliser un échantillon à une population).
- Identifier les 4 types de variables : Qualitative Nominale, Qualitative Ordinale, Quantitative Discrète, Quantitative Continue.
- Savoir choisir la mesure centrale adaptée : Moyenne (toutes valeurs égales), Médiane (insensible aux valeurs aberrantes), Mode (valeur prédominante).
- Maîtriser les formules équivalentes entre Excel (Français/Anglais) et Python (bibliothèque statistics).

1. INTRODUCTION & DEUX GRANDES BRANCHES DES STATISTIQUES

Concepts Clés

- Définition des statistiques : Branche des mathématiques appliquées dédiée à la collecte, l'analyse, l'interprétation, la présentation et l'organisation des données chiffrées.
- Objectif décisionnel : Transformer des données brutes en informations stratégiques et éclairer les prises de décision managériales.
- Statistique Descriptive : Vise à résumer et exposer les caractéristiques d'une population ou d'un jeu de données sans chercher à extrapoler (décrire).
- Statistique Inférentielle : Utilise un échantillon représentatif et les lois de probabilités pour projeter et généraliser des conclusions à l'ensemble de la population (généraliser).

Vocabulaire Fondamental :
• Population : L'ensemble global des éléments étudiés.
• Individu (ou Unité Statistique) : Chaque élément unique composant la population.
• Caractère (ou Variable) : La propriété spécifique observée ou mesurée sur chaque individu (ex: Âge, Salaire, Position).

2. TYPOLOGIE RIGOUREUSE DES VARIABLES STATISTIQUES

Classification

- Variable Qualitative Nominale : Catégories qualitatives sans hiérarchie ni ordre mathématique (exemples : couleur des yeux, marque d'ordinateur, sexe, position d'un joueur).
- Variable Qualitative Ordinale : Catégories présentant un ordre ou un classement naturel (exemples : niveau d'étude [primaire < secondaire < supérieur], degré de satisfaction [faible < moyen < élevé], classement d'une équipe).
- Variable Quantitative Discrète : Valeurs numériques entières obtenues par comptage (exemples : nombre d'enfants par famille, nombre d'élèves dans une classe, nombre de buts marqués).
- Variable Quantitative Continue : Valeurs numériques pouvant prendre une infinité de décimales, obtenues par mesure physique (exemples : taille en mètres, poids en kg, température en °C, temps de jeu en minutes).

Règle Mémo pour l'Examen :
Posez-vous deux questions simples :
1. Peut-on calculer une moyenne numérique ? Si NON → Qualitative (ordonnée ? oui = Ordinale, non = Nominale).

2. Si OUI (Quantitative) : Est-ce un résultat de comptage entier (Discrète) ou de mesure avec virgule possible (Continue) ?

3. LES TROIS MESURES DE TENDANCE CENTRALE

Moyenne, Médiane, Mode

- Moyenne arithmétique (Mean / Average) : Somme de toutes les valeurs divisée par l'effectif total. Utile quand toutes les observations ont une importance égale, mais très vulnérable aux valeurs aberrantes.
- Médiane (Median) : Valeur centrale séparant la distribution triée en deux moitiés égales (50% en dessous, 50% au-dessus). Propriété fondamentale : hautement résiliente (insensible) aux valeurs extrêmes.
- Règle de calcul de la médiane : Si l'effectif N est impair → valeur exacte au rang (N+1)/2 ; si N est pair → moyenne arithmétique des deux valeurs centrales aux rangs N/2 et (N/2)+1.
- Mode (Mode) : Valeur apparaissant avec la fréquence maximale dans la série. Utile pour repérer la situation la plus courante ou dominante (peut être unimodal, bimodal ou multimodal).

$$\text{Formule : Moyenne : } \bar{X} = \frac{\sum_{i=1}^n x_i}{n} \quad | \quad \text{Médiane} = \text{Valeur à 50\% de la série ordonnée}$$

Exemple d'Application (Exercice du cours) :
Notes d'un contrôle : [8, 10, 10, 10, 12, 14, 16, 18] (8 notes)
• Moyenne = (8 + 10*3 + 12 + 14 + 16 + 18) / 8 = 98 / 8 = 12.25
• Médiane = moyenne des 4e et 5e notes (10 + 12)/2 = 11
• Mode = 10 (apparaît 3 fois)

4. IMPLÉMENTATIONS PRATIQUES (EXCEL VS PYTHON)

Outils

- Formules Excel : Disponibles en versions française et anglaise :
- • Moyenne : =MOYENNE(B2:B11) ↔ =AVERAGE(B2:B11)
- • Médiane : =MEDIANE(B2:B11) ↔ =MEDIAN(B2:B11)
- • Mode simple : =MODE.SIMPLE(B2:B11) ↔ =MODE.SNGL(B2:B11)
- En Python standard : Utilisation du module natif `statistics` pour une analyse rapide et sans dépendance lourde.

SÉANCE 02

Mesures de Dispersion & Détection Univariée des Outliers (2-Sigma)

Mesurer la variabilité et l'homogénéité des données via l'étendue, la variance et l'écart-type, et implémenter la méthode statistique des deux écarts-types pour isoler les valeurs aberrantes.

POINTS FONDAMENTAUX À RETENIR :

- Les mesures centrales ne suffisent pas : deux séries peuvent avoir la même moyenne tout en ayant des comportements totalement divergents.
- Comprendre la différence mathématique cruciale entre variance d'échantillon (diviseur n-1) et variance de population (diviseur n).
- L'écart-type (σ) s'exprime dans la même unité de mesure que la variable initiale, ce qui le rend directement interprétable.
- Appliquer la règle des deux écarts-types : sous hypothèse de distribution normale, toute valeur en dehors de [Moyenne - 2σ, Moyenne + 2σ] est suspectée d'anomalie.

1. POURQUOI MESURER LA DISPERSION ?

Motivation

- Complémentarité absolue : La moyenne donne le point d'ancrage central, mais la dispersion indique si les observations sont regroupées ou très étalées.
- Interprétation managériale : Une faible dispersion révèle un groupe homogène et prévisible ; une forte dispersion signale une forte hétérogénéité ou de grandes inégalités (ex: salaires).

2. L'ÉTENDUE (RANGE)

Mesure Simple

- Définition : Différence arithmétique simple entre la valeur maximale et la valeur minimale d'une série ordonnée.
- Formule : E = x(max) - x(min) = x(n) - x(1).
- Avantage : Calcul immédiat et intuitif.
- Limitations majeures : Ne tient compte d'aucune observation intermédiaire ; est excessivement sensible à une seule valeur extrême ou erreur de frappe.

```
Formule : E = x_{\max} - x_{\min}
```

Impact d'une Seule Valeur Extrême :
Soit la série de notes : [8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 2].
• Avec la note 2 : Étendue = 18 - 2 = 16 points (illusion d'une dispersion énorme).
• Sans la note 2 (valeur aberrante) : Étendue = 18 - 8 = 10 points.

3. VARIANCE ET ÉCART-TYPE (STANDARD DEVIATION)

Mesures Complètes

- Variance (σ^2) : Moyenne des carrés des écarts de chaque point par rapport à la moyenne globale.
- Pourquoi élever au carré ? Pour éliminer les signes négatifs (qui s'annuleraient à la somme) et pénaliser plus lourdement les grands éloignements.
- Variance d'échantillon (Sample Variance) : Divisée par (n - 1) au lieu de n pour corriger le biais statistique (correction de Bessel).
- Écart-type (σ) : Racine carrée positive de la variance. Atout majeur : il s'exprime dans la même unité physique que les données initiales (DH, kg, minutes, cm).

$$\text{Formule : } \text{Variance échantillon } s^2 = \frac{\sum_{i=1}^n (x_i - \bar{X})^2}{n - 1} \quad | \quad \text{Écart-type } s = \sqrt{s^2}$$

4. MÉTHODE DES DEUX ÉCARTS-TYPES (2-SIGMA METHOD)

Détection d'Outliers

- Hypothèse : Les données suivent approximativement une distribution normale (courbe en cloche).
- Principe probabiliste : Dans une loi normale, environ 95.45% des observations se trouvent dans l'intervalle [Moyenne - 2σ, Moyenne + 2σ].
- Seuil Supérieur (Ss) = Moyenne + 2 × σ
- Seuil Inférieur (Si) = Moyenne - 2 × σ
- Critère de détection : Tout point x < Si ou x > Ss est classé comme valeur aberrante (outlier univarié).

SÉANCE 03

Mesures de Position & Détection par IQR, Tukey et Box Plots

Explorer les quartiles, déciles et centiles, comprendre les causes et impacts des anomalies, et appliquer les méthodes de l'IQR, de Tukey, des boîtes à moustaches et du Z-Score.

POINTS FONDAMENTAUX À RETENIR :

- Les mesures de position ordonnent la distribution en fractions égales : Quartiles (4 parties de 25%), Déciles (10 parties de 10%), Centiles (100 parties de 1%).
- Comprendre les 6 grandes causes d'outliers (erreur humaine, mesure, échantillonnage, traitement, expérimentale, ou nouveauté naturelle).
- La méthode de l'Intervalle Interquartile (IQR = Q3 - Q1) avec seuils [Q1 - 1.5*IQR, Q3 + 1.5*IQR] est non paramétrique et insensible aux valeurs extrêmes.
- La méthode de Tukey utilise k = 3 au lieu de 1.5 pour isoler uniquement les anomalies extrêmes et préserver plus de données.
- Le Z-Score mesure l'écart en nombre de déviations standard : un point est généralement suspect si |Z| > 3.

1. LES MESURES DE POSITION (QUARTILES, DÉCILES, CENTILES)

Division Ordonnée

- Quartiles : Divisent l'échantillon ordonné en 4 parties égales contenant 25% des observations :
- • Q1 (1er quartile) : 25% des valeurs sont inférieures ou égales.
- • Q2 (2e quartile) : 50% des valeurs sont inférieures (équivaut exactement à la Médiane).
- • Q3 (3e quartile) : 75% des valeurs sont inférieures (et 25% supérieures).
- Déciles : Divisent les données en 10 segments de 10% chacun (D1 = 10%, D5 = médiane, D9 = 90%).
- Centiles (Percentiles) : Divisent en 100 tranches de 1% (ex: C95 = 95% des valeurs sont inférieures).

Exemple Pratique du Cours :
Si dans un concours de Data Analyst :
• Q1 = 7.5/20 → 25% des candidats ont eu 7.5 ou moins.
• D5 = 16/20 → 50% des candidats sont sous 16/20.
• C95 = 19/20 → Seuls 5% des candidats ont décroché plus de 19/20 !

2. CAUSES & STRATÉGIES DE GESTION DES VALEURS ABERRANTES

Audit de Qualité

- Définition : Une valeur aberrante (outlier) est un point de donnée situé à une distance anormale du reste du nuage.
- Impact néfaste : Peut fausser lourdement les estimations (gonflement artificiel de la moyenne, étirement de la variance) et perturber les modèles de Machine Learning (régression linéaire, etc.).
- Les 6 causes identifiées dans le cours :
- 1. Erreur humaine : Saisie manuelle erronée (ex: taper 1500 au lieu de 15).
- 2. Erreur d'échantillonnage : L'échantillon ne reflète pas fidèlement la population cible.
- 3. Erreurs expérimentales : Erreur survenue pendant la procédure d'extraction des données.
- 4. Erreurs de mesure : Dérive ou imprécision des capteurs physiques ou instruments.
- 5. Erreurs de traitement : Bug ou altération lors de la manipulation/transformation du pipeline.

- 6. Anomalies réelles / Naturelles : Événement authentique mais rare (ex: transaction bancaire frauduleuse, vente exceptionnelle).
- Les 3 stratégies de traitement :
- • Remplacement (Imputation) : Remplacer par la médiane ou la moyenne pour préserver la taille du dataset.
- • Suppression : Éliminer la ligne si et seulement si l'erreur est manifestement non corrigible et invalide.
- • Conservation / Acceptation : Conserver l'outlier s'il porte une valeur métier stratégique (détection de fraude, cyber-intrusion).

3. LA MÉTHODE DE L'IQR & VARIANTE DE TUKEY

Règles Mathématiques

- Calcul de l'Écart Interquartile : IQR = Q3 - Q1 (couvre les 50% centraux du jeu de données).
- Limites standard (k = 1.5) :
- • Limite inférieure = Q1 - 1.5 × IQR
- • Limite supérieure = Q3 + 1.5 × IQR
- Méthode de Tukey (k = 3.0) : Définit les "outliers extrêmes". En fixant k = 3, on tolère une plus grande marge et on élimine moins de points.
- Atout déterminant : L'IQR ne dépend ni de la moyenne ni de la variance, elle ne requiert pas de distribution normale gaussienne.

$$\text{Formule : } \text{IQR} = Q_3 - Q_1 \quad | \quad \text{Seuil}_{inf} = Q_1 - 1.5 \cdot \text{IQR} \quad | \quad \text{Seuil}_{sup} = Q_3 + 1.5 \cdot \text{IQR}$$

4. BOX PLOT (BOÎTE À MOUSTACHES) & Z-SCORE

Visualisation & Standardisation

- Box Plot : Outil graphique compact visualisant la structure de la distribution :
- • La boîte centrale délimite le 1er quartile (Q1) et le 3e quartile (Q3).
- • Le trait interne représente la Médiane (Q2).
- • Les moustaches (whiskers) s'étendent jusqu'aux valeurs extrêmes non aberrantes (au maximum 1.5 × IQR).
- • Tous les points tracés au-delà des moustaches sont des outliers graphiques.
- Z-Score (Cote standard) : Exprime à combien d'écarts-types un point x se situe de la moyenne.
- • Formule : Z = (x - Moyenne) / Écart-type.
- • Interprétation : Z = 0 indique que le point est exactement à la moyenne ; un Z > 0 est supérieur, Z < 0 est inférieur.
- • Règle de décision usuelle : Un point dont le Z-score dépasse +3 ou descend sous -3 est considéré comme outlier.

SÉANCE 04

Standardisation, Normalisation & Algorithmes Avancés (Isolation Forest, DBSCAN)

Distinguer les approches de mise à l'échelle des variables et maîtriser les algorithmes avancés de détection d'anomalies multidimensionnelles (Isolation Forest et DBSCAN).

POINTS FONDAMENTAUX À RETENIR :

- Standardisation vs Normalisation : Le choix dépend directement de la nature de l'algorithme de Machine Learning utilisé.
- La Standardisation produit une moyenne nulle (0) et une variance unitaire (1), avec des valeurs non bornées (idéale pour ACP, Régression, K-Means).
- La Normalisation compresse les valeurs dans l'intervalle fixe [0, 1] sans changer l'allure de la distribution (idéale pour Réseaux de Neurones, KNN).
- Isolation Forest isole directement les anomalies via des arbres binaires sans modéliser le comportement normal au préalable.
- DBSCAN est un algorithme de clustering par densité qui repère simultanément les clusters de forme arbitraire et classe les points non denses comme bruit/outliers (label -1).

1. STANDARDISATION VS NORMALISATION : COMPARATIF RIGOUREUX

Préparation des Données

- Standardisation (Z-Score Scaling) :
- • Objectif mathématique : Centrer et réduire la distribution (Moyenne = 0, Écart-type = 1).
- • Effet : Valeurs non bornées (positives et négatives). Les outliers se détachent au-delà de ±3.
- • Applications privilégiées : Régression Linéaire et Logistique, Analyse en Composantes Principales (ACP/PCA), K-Means clustering (pour empêcher une variable aux grands chiffres d'écraser les autres).
- Normalisation (Min-Max Scaling) :
- • Objectif mathématique : Échelonner linéairement les données dans un intervalle fermé fixe, habituellement [0, 1].
- • Effet : Les données sont bornées entre 0 et 1 sans modifier la forme originelle de la distribution.
- • Applications privilégiées : Réseaux de neurones profonds (permet une convergence rapide du gradient sans explosion), K-Nearest Neighbors (KNN - calcul équitable des distances euclidiennes), interfaces de dataviz.

$$\text{Formule : } z = \frac{x - \mu}{\sigma} \quad \Longleftrightarrow \quad \text{Normalisation Min-Max : } x_{\text{norm}} = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Tableau Comparatif Rapide :
• Standardisation : Moyenne = 0, Variance = 1 | Plage [-∞, +∞] | Sensible aux outliers : Modéré | Modèles : K-Means, ACP, SVM, Régression.
• Normalisation : Plage bornée stricte [0, 1] | Forme conservée | Sensible aux outliers : Très sensible | Modèles : Deep Learning, KNN.

2. ISOLATION FOREST (FORÊT D'ISOLATION)

Détection d'Intrusions

- Concept fondateur : Les anomalies sont "rares et quantitativement différentes".
- Changement de paradigme : Contrairement aux approches classiques qui cherchent à modéliser la "normalité" pour détecter les écarts, Isolation Forest cible et isole directement les

anomalies.

- Mécanisme interne : Des arbres binaires de partition aléatoire (iTrees) découpent l'espace de caractéristiques.
- Critère de détection : Les points normaux, situés au cœur de groupes denses, exigent de nombreuses subdivisions pour être isolés. À l'inverse, les anomalies sont isolées très près de la racine avec très peu de coupures (profondeur d'arbre courte).

3. L'ALGORITHME DBSCAN (CLUSTERING SPATIAL PAR DENSITÉ)

Multi-Clustering

- DBSCAN = Density-Based Spatial Clustering of Applications with Noise.
- Atout clé : Détecte des formes géométriques arbitraires et complexes là où K-Means échoue (formes concaves, anneaux, grappes irrégulières).
- Fonctionnement multidimensionnel : Prend en compte simultanément plusieurs colonnes / dimensions, surpassant les méthodes univariées (2-sigma, IQR).
- Les deux hyperparamètres fondamentaux :
- 1. `eps` (Epsilon) : Rayon maximal de distance pour considérer qu'un point est voisin d'un autre.
- 2. `min_samples` : Nombre minimal de points nécessaires dans le voisinage de rayon `eps` pour constituer une zone dense.
- Typologie des points classés par DBSCAN :
- • Points centraux (Core points) : Possèdent au moins `min_samples` voisins dans leur rayon `eps`.
- • Points frontières (Border points) : Voisins d'un point central mais n'ayant pas eux-mêmes assez de voisins.
- • Bruit / Outliers (Noise points) : Ne font partie d'aucun cluster dense. Ils reçoivent automatiquement l'étiquette `label = -1`.

SÉANCES 05 & 06

Probabilités Avancées, Machine Learning Naive Bayes & Monte Carlo

Maîtriser la probabilité conditionnelle et le théorème de Bayes, implémenter les trois variantes de classificateurs Naive Bayes (Multinomial, Bernoulli, Gaussian) et appréhender la simulation stochastique de Monte Carlo.

POINTS FONDAMENTAUX À RETENIR :

- Probabilité conditionnelle : P(A|B) est la probabilité que A survienne sachant que l'événement B est déjà avéré.
- Théorème de Bayes : Permet de calculer la probabilité a posteriori P(A|B) en combinant la vraisemblance P(B|A) et les probabilités marginales.
- Variantes de Naive Bayes : MultinomialNB pour les fréquences de mots (NLP / Spam), BernoulliNB pour la présence/absence binaire, GaussianNB pour les grandeurs continues (mesures médicales).
- Pipeline de classification de texte : Tokenisation et vectorisation (CountVectorizer) combinée à MultinomialNB pour filtrer les spams.
- Simulation de Monte Carlo : S'appuie sur la loi des grands nombres pour modéliser des phénomènes complexes par tirages aléatoires successifs.

1. PROBABILITÉ CONDITIONNELLE & THÉORÈME DE BAYES

Fondations Mathématiques

- Probabilité Conditionnelle : P(A|B) quantifie la probabilité de survenue de l'événement A sous condition préalable de réalisation de B.
- Formule conditionnelle : P(A|B) = P(A ∩ B) / P(B) avec P(B) > 0.
- Exemples concrets du cours : Probabilité de pluie sachant que le ciel est couvert ; probabilité qu'une pièce soit défectueuse sachant la machine de production employée.
- Théorème de Bayes : Outil probabiliste fondamental pour réviser et actualiser une croyance ou un diagnostic suite à l'observation d'une nouvelle preuve ou d'indices récents.
- Domaines d'excellence : Diagnostic médical (probabilité d'une pathologie sachant des symptômes précis) et filtrage prédictif (probabilité qu'un e-mail soit un pourriel).

$$\text{Formule : } P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)} \quad \text{avec } P(B) > 0$$

Terminologie Bayésienne :

• P(A) : Probabilité a priori (prior belief).
• P(B|A) : Vraisemblance (likelihood).
• P(B) : Probabilité marginale totale de la preuve.
• P(A|B) : Probabilité a posteriori (posterior probability mise à jour).

2. LES TROIS VARIANTES DU CLASSIFICATEUR NAIVE BAYES

Machine Learning

- Hypothèse "Naïve" : Supposée indépendance conditionnelle de toutes les caractéristiques prédictives entre elles sachant la classe cible.
- 1. MultinomialNB : Adapté aux variables représentant des fréquences, des scores d'occurrence ou des décomptes discrets. Idéal pour le Traitement du Langage Naturel (NLP), la détection de spam et l'analyse de sentiment.
- 2. BernoulliNB : Adapté aux variables d'état purement binaires (0 ou 1, VRAI ou FAUX). En classification textuelle, il s'intéresse uniquement à la présence ou à l'absence d'un mot, sans tenir compte du nombre de répétitions.

- 3. GaussianNB : Adapté aux variables continues qui suivent une loi normale (gaussienne). Utilisé en biométrie, signaux capteurs, imagerie médicale (ex: température corporelle, glycémie, pression artérielle).

3. PROJET PRATIQUE : DÉTECTION DE SPAM AVEC SCIKIT-LEARN

Pipeline NLP

- Étape 1 : Chargement du fichier `spam.csv` avec Pandas et exploration des valeurs nulles.
- Étape 2 : Encodage de la variable cible : conversion de "spam" en 1 et "ham" (légitime) en 0.
- Étape 3 : Séparation du jeu de données en entraînement (Train 75%) et test (Test 25%) via `train_test_split`.
- Étape 4 : Création d'un pipeline scikit-learn chaînant `CountVectorizer()` (création de la matrice sac de mots) et `MultinomialNB()`.
- Étape 5 : Entraînement du modèle avec `clf.fit(X_train, y_train)` et évaluation de la précision (accuracy) avec `clf.score(X_test, y_test)`.
- Étape 6 : Prédiction en temps réel sur de nouveaux e-mails pour tester la classification.

4. SIMULATION STOCHASTIQUE DE MONTE CARLO

Échantillonnage Aléatoire

- Fondement : Tirages d'échantillons aléatoires répétés pour approximer les paramètres statistiques d'une population complexe.
- Loi des grands nombres : Au fur et à mesure que la taille de l'échantillon augmente, la moyenne observée converge vers l'espérance mathématique réelle de la population.
- Expérience pratique du cours : Population synthétique de 1000 individus (hauteur moyenne réelle = 170 cm, écart-type = 10 cm).
- Résultats comparatifs selon la fraction de population échantillonnée :
- • Échantillon 10% (100 personnes) : Moyenne estimée ≈ 171.38 cm, écart-type ≈ 10.38 (estimation très fidèle).
- • Échantillon 5% (50 personnes) : Moyenne estimée ≈ 170.86 cm (bonne représentativité globale).
- • Échantillon 0.5% (5 personnes) : Moyenne estimée ≈ 168.88 cm (imprécision plus marquée, sensibilité aux aléas).
- Conclusion méthodologique : La simulation de Monte Carlo fonctionne remarquablement bien sur des données distribuées normalement et centrées.

SÉANCE 07

Vulgarisation du Langage R & Environnement RStudio

Découvrir la genèse et les atouts du langage R, appréhender l'IDE RStudio et ses 4 quadrants, maîtriser la syntaxe élémentaire, le typage dynamique, les opérateurs vectoriels et R Markdown.

POINTS FONDAMENTAUX À RETENIR :

- R est un langage et environnement interprété créé en 1993 par Ross Ihaka et Robert Gentleman (Université d'Auckland), successeur du langage S.
- RStudio structure le flux de travail en 4 zones majeures : Éditeur (scripts .R), Console (exécution instantanée), Environnement/Historique/Connexions, Fichiers/Graphiques/Packages/Help/Viewer.
- R Markdown (.Rmd) permet de concevoir des rapports et présentations dynamiques et reproductibles en formats HTML, PDF ou Word.
- Opérateurs singuliers en R : Affectation via <- (ou =), vérification d'appartenance avec %in%, produit matriciel %*%, et division entière %/%.
- Typage dynamique sans déclaration explicite : vérifié via class() ou typeof().

1. HISTOIRE, ÉCOSYSTÈME & ATOUTS MAJEURS DE R

Origines & Forces

- Historique : Dérivé du langage S (Bell Labs, 1976), R a été formalisé en 1993 par Ross Ihaka et Robert Gentleman à Auckland pour l'enseignement statistique.
- Statut : Logiciel libre (Open Source) et multiplateforme (Windows, macOS, Linux) sous l'égide du R Core Team (depuis 1997).
- Points forts pour l'analyse décisionnelle :
- • Écosystème gigantesque de packages sur le CRAN (Comprehensive R Archive Network).
- • Puissance graphique inégalée avec support natif des symboles mathématiques et packages modernes comme ggplot2.
- • Interopérabilité élevée avec d'autres langages de bas niveau (C, C++, Java).
- • Reproductibilité scientifique totale grâce à R Markdown et Quarto.

2. VISITE GUIDÉE DE L'IDE RSTUDIO (LES 4 QUADRANTS)

Interface RStudio

- 1. Zone Édition (En haut à gauche) : Espace de rédaction des scripts R et documents `.Rmd`, avec autocomplétion, vérification de syntaxe et coloration.
- 2. Zone Console (En bas à gauche) : Interpréteur interactif pour tester des commandes en temps réel et observer immédiatement les retours sans compilation.
- 3. Zone Environnement / Historique / Connexions / Tutoriels (En haut à droite) :
- • Environment : Liste les variables, DataFrames et objets actifs en mémoire.
- • History : Historique chronologique de toutes les commandes passées.
- • Connections : Gestionnaire de liaisons aux bases de données relationnelles (ODBC) ou distribuées (Apache Spark).
- 4. Zone Fichiers / Plots / Packages / Aide / Viewer (En bas à droite) :
- • Files : Explorateur de fichiers du répertoire de travail.
- • Plots : Fenêtre de prévisualisation et d'exportation des graphiques (PDF/PNG).
- • Packages : Outil graphique pour installer et mettre à jour les librairies CRAN.
- • Help : Documentation officielle détaillée des fonctions et jeux de données.
- • Viewer : Rendu des sorties web interactives (HTML, tables dynamiques, cartes Leaflet).

3. SYNTAXE DE BASE, ASSIGNATION & TYPAGE EN R

Grammaire du Code

- Assignation standard : Utilisation de l'opérateur flèche `<-` (recommandé en R) ou du signe `=` (ex: `age <- 25`).
- Assignation inversée : `25 -> age` est parfaitement valide en R.
- Assignation globale : `<<-` permet d'assigner une variable dans l'environnement parent ou global.
- Typage dynamique : Une variable ne requiert aucune déclaration préalable de type et peut changer à la volée.
- Types de données fondamentaux :
- • numeric : Nombres réels à virgule flottante (ex: `taille <- 1.75`).
- • integer : Nombres entiers stricts, notés avec un suffixe majuscule L (ex: `annee <- 2026L`).
- • character : Chaînes de texte entre guillemets (ex: `nom <- "Data Analyst"`).
- • logical : Booléens stricts écrits en majuscules `TRUE` ou `FALSE` (ou `T` / `F`).
- Inspection des types : `class(var)` renvoie la classe conceptuelle, tandis que `typeof(var)` indique le type de stockage mémoire interne.

4. OPÉRATEURS ARITHMÉTIQUES, LOGIQUES & SPÉCIFIQUES À R

Opérateurs

- Opérateurs Arithmétiques : `+` (addition), `-` (soustraction), `*` (multiplication), `/` (division), `^` (puissance/exposant).
- Opérateurs de Division Spécifiques :
- • Modulo : `%%` (reste de la division entière, ex: `10 %% 3` renvoie `1`).
- • Division entière : `%/%` (quotient entier sans reste, ex: `10 %/% 3` renvoie `3`).
- Attention piège R vs Python : En R, on ne peut PAS additionner des chaînes de caractères avec `+` (provoque une erreur "argument non numérique"). On utilise `paste()` ou `paste0()`.
- Opérateurs Logiques :
- • Élément par élément sur vecteurs : `&` (ET logique) et `|` (OU logique).
- • Évaluation courte (scalaire unique) : `&&` et `||`.
- • Négation : `!` (ex: `!TRUE` renvoie `FALSE`).
- Opérateurs Divers indispensables :
- • Générateur de séquence `:` (ex: `1:10` génère le vecteur `c(1, 2, ..., 10)`).
- • Appartenance `%in%` : Teste si un élément se trouve dans un ensemble (ex: `5 %in% c(1, 3, 5, 7)` renvoie `TRUE`).
- • Produit matriciel `%*%` : Effectue la vraie multiplication matricielle de l'algèbre linéaire.
- Fonctions mathématiques de base : `sqrt()`, `exp()`, `log()`, `log10()`, `abs()`, `round(x, digits=2)`, `floor()`, `ceiling()`, `sin()`, `cos()`, `tan()`.

SÉANCE 11

Visualisation des Données Décisionnelles & Datastorytelling

Adopter une utilisation stratégique et inclusive des couleurs, éviter les pièges de surcharge visuelle, et maîtriser l'anatomie complète des annotations pour concevoir des dashboards décisionnels percutants.

POINTS FONDAMENTAUX À RETENIR :

- Astuce 0 : Élargir sa compréhension de la couleur. Bannir les couleurs pures criardes au profit de nuances subtiles, de teintes atténuées et de transparences.
- La combinaison maîtresse universelle : Le duo Bleu + Orange/Rouge offre un contraste maximal tout en restant parfaitement discernable pour les personnes atteintes de daltonisme.
- Règle de sobriété : Limiter drastiquement le nombre de teintes d'une palette (3 à 5 au maximum) pour prévenir la fatigue cognitive des décideurs.
- Adapter la palette à la nature de la variable : Palette séquentielle pour du continu, palette divergente pour des variations autour d'un neutre, palette catégorielle pour des groupes distincts.
- Les 6 piliers des annotations : Titre percutant, libellés d'axes complets avec unité de mesure (ex: Ventes en DH), légendes claires, barres de couleur, callouts spécifiques et repères visuels.

1. STRATÉGIE DES COULEURS & ACCESSIBILITÉ VISUELLE

Théorie de la Couleur

- Impact décisionnel : Une couleur mal choisie induit des biais cognitifs ou rend la lecture d'un rapport fastidieuse.
- Astuce 0 - Nuances & Transparence : Éviter les couleurs primaires 100% saturées. Privilégier les gammes douces ou désaturées qui confèrent une élégance professionnelle.
- Le couple roi : Bleu et Orange/Rouge :
- • Les couleurs chaudes (jaune, orange, rouge) attirent immédiatement le regard vers l'information prioritaire.
- • Le bleu est apaisant, neutre, inspire la confiance managériale et se décline en de multiples tonalités (clair, marine, cyan).
- • Accessibilité universelle : Les personnes daltoniennes (deutéranopie, protanopie) distinguent parfaitement le bleu de l'orange/rouge.
- Consistance & Sémantique intuitive : Attribuer toujours la même couleur à une catégorie donnée à travers l'ensemble d'un dashboard (ex: Rouge pour alerte/perte, Vert pour sécurité/croissance).

Principe d'Accessibilité (Pr. SADRATI) :
"En cas de doute, utilisez un orange/rouge avec du bleu." C'est la combinaison préférée des rédactions de presse économique de renommée mondiale (South China Morning Post, The Economist).

2. CHOIX DE PALETTE & OUTILS (PYTHON SEABORN VS R GGPLOT2)

Palettes Logicielles

- Palette restreinte : Réduire au minimum strict le nombre de teintes différentes pour éviter l'effet "arc-en-ciel" illisible.
- Types de palettes adaptées :
- • Palette Séquentielle : Dégradé clair vers foncé pour une variable quantitative continue ordonnée (ex: température, volume de vente).
- • Palette Catégorielle : Couleurs contrastées pour des classes nominales (ex: magasins A, B, C).

- • Palette Divergente : Deux teintes opposées convergeant vers un milieu neutre (ex: bénéfices positifs en bleu vs pertes négatives en rouge).
- En Python (Seaborn & Matplotlib) : Utilisation de palettes intégrées comme `sns.color_palette("muted")` ou `palette="pastel"`, et dictionnaires personnalisés pour contrôler chaque catégorie.
- En R (ggplot2) : Contrôle manuel avec `scale_color_manual()` ou adoption du package moderne `viridis`, réputé pour sa perception uniforme et son accessibilité aux daltoniens.

3. L'ART DES ANNOTATIONS : LES 6 ÉLÉMENTS CLÉS D'UN BON GRAPHIQUE

Datastorytelling

- 1. Le Titre : Doit énoncer le message ou la conclusion clé, et non simplement répéter le nom des axes.
- 2. Étiquettes d'axes (X et Y) : Règle absolue : Toujours préciser le nom complet de la variable suivi de son unité de mesure (ex: "Ventes mensuelles (en milliers de DH)", "Consommation (miles par gallon)").
- 3. Légendes (Key) : Indispensables pour associer sans ambiguïté les formes de points ou les couleurs aux modalités.
- 4. Barres de couleur (Colorbar) : Présentent l'échelle d'étalonnage pour les variables numériques continues en 3e dimension.
- 5. Annotations spécifiques (Callouts) : Flèches textuelles pointant directement vers un événement anormal, un pic saisonnier ou une rupture de tendance.
- 6. Repères visuels : Lignes horizontales ou verticales en pointillés matérialisant des seuils d'alerte, des objectifs contractuels ou la moyenne globale.

Tableau Synthétique des Formules & Syntaxes Logicielles

Tableau de référence croisée préparé pour les examens et projets analytiques.

CONCEPT / FORMULE	FORMULE MATHÉMATIQUE	SYNTAXE PYTHON	SYNTAXE R
Moyenne Arithmétique	`\bar{X} = \frac{1}{n}\sum_{i=1}^n x_i`	`np.mean(data)` ou `statistics.mean(data)`	`mean(data)`
Médiane	`Q_2 = \text{Rang } \frac{n+1}{2} \text{ ou moyenne des deux rangs centraux}`	`np.median(data)` ou `statistics.median(data)`	`median(data)`
Variance Échantillon	`s^2 = \frac{1}{n-1}\sum_{i=1}^n (x_i - \bar{X})^2`	`np.var(data, ddof=1)`	`var(data)`
Écart-Type Échantillon	`s = \sqrt{s^2} = \sqrt{\frac{1}{n-1}\sum_{i=1}^n (x_i - \bar{X})^2}`	`np.std(data, ddof=1)`	`sd(data)`
Écart Interquartile (IQR)	`\text{IQR} = Q_3 - Q_1`	`q3 - q1` avec `np.percentile(data, [25, 75])`	`IQR(data)`
Bornes de Détection 2-Sigma	`[\bar{X} - 2s, \; \bar{X} + 2s]`	`[mean - 2*std, mean + 2*std]`	`c(mean(x) - 2*sd(x), mean(x) + 2*sd(x))`
Bornes de Détection IQR / Tukey	`[Q_1 - k \cdot \text{IQR}, \; Q_3 + k \cdot \text{IQR}] \quad (k=1.5 \text{ ou } 3)`	`[q1 - 1.5*iqr, q3 + 1.5*iqr]`	`boxplot.stats(x)$out`
Z-Score (Standardisation)	`z = \frac{x - \bar{X}}{s}`	`(data - np.mean(data)) / np.std(data)`	`scale(data)`
Normalisation Min-Max	`x_{\text{norm}} = \frac{x - x_{\min}}{x_{\max} - x_{\min}}`	`(data - data.min()) / (data.max() - data.min())`	`(x - min(x)) / (max(x) - min(x))`
Théorème de Bayes	`P(A|B) = \frac{P(B|A)`	`MultinomialNB()` de `sklearn.naive_bayes`	`naiveBayes()` de `e1071`

CONCEPT / FORMULE	FORMULE MATHÉMATIQUE	SYNTAXE PYTHON	SYNTAXE R
	`\cdot P(A)}{P(B)}`		