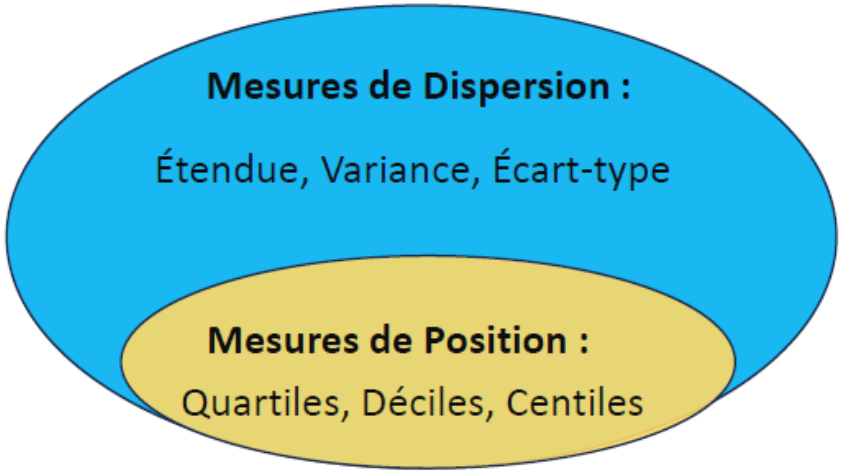
Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

- ***Les mesures de position*** indiquent la position relative d'une valeur par rapport aux autres dans un ensemble de données.

À la base, deux des mesures de position couramment utilisées sont le ***minimum*** et le ***maximum*** d'une distribution, qui correspondent respectivement à la valeur la moins élevée et à la valeur la plus élevée de cette dernière. Par contre, il existe d'autres mesures qui requièrent légèrement plus de réflexion de la part de ceux qui les utilisent. ***Quartiles, Déciles, Centiles***



Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Mesure de position :Quartiles

Les quartiles sont des valeurs qui divisent un ensemble de données triées en quatre parties égales, chacune représentant 25% des données.

Calcul : $Q1$ (premier quartile) est à 25%, $Q2$ (**deuxième quartile ou médiane**) est à 50%, $Q3$ (troisième quartile) est à 75%.

Interprétation : $Q1$ représente le point où 25% des données sont inférieures, ***Q2* est la médiane**, et $Q3$ représente le point où 75% des données sont inférieures.

Q1 : 25%
Premier quartile

Q2 : 50%
Médiane

Q3 : 75%
Troisième quartile

Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Mesure de position :Déciles

Les déciles sont des valeurs qui divisent un ensemble de données triées en dix parties égales, chaque décile représentant **10%** des données.

Calcul : $D1$ à $D9$ représentent respectivement 10% à 90%, et $D10$ est équivalent au centile.

Interprétation : Les déciles permettent de visualiser la distribution des données en segments de 10%.

D1 : 10%

Premier décile

D2 : 20%

Deuxième décile

...

Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Mesure de position :Centiles

Les centiles sont des valeurs qui divisent un ensemble de données ***triées*** en cent parties égales, chaque centile représentant 1% des données.

Calcul : $C1$ à $C99$ représentent respectivement 1% à 99%, et $C100$ est la valeur maximale.

Interprétation : Les centiles permettent de quantifier la position d'une valeur spécifique par rapport à l'ensemble des données.

C1 : 1%
Premier centile

C2 : 2%
Deuxième centile

...

Approfondir les Systèmes Décisionnels

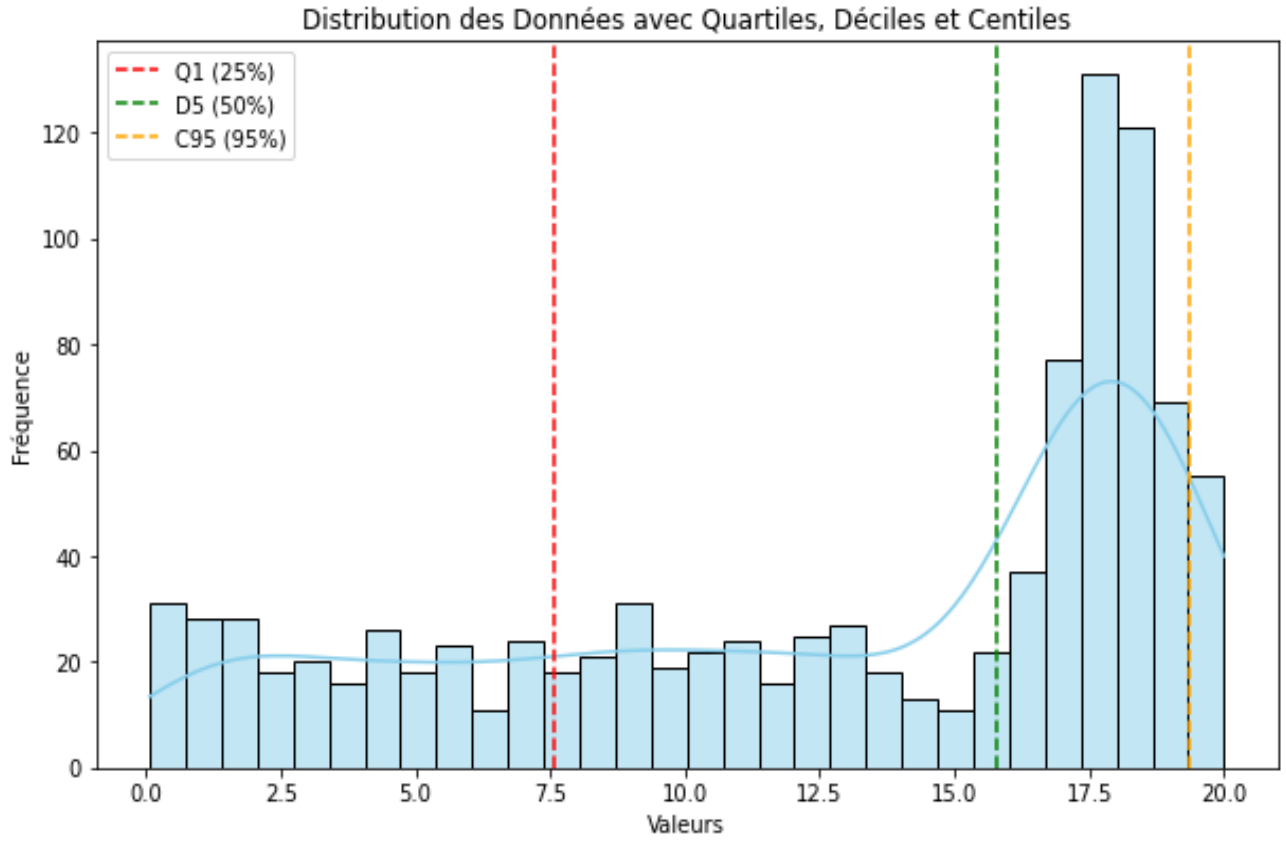
Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Exemple d'application aux résultats des étudiants : Interprétation et Analyse des Quartiles, Déciles et Centiles

- Si $Q1$ dans un ensemble de notes est égal à 7,5, cela signifie que 25% des étudiants ont obtenu 7,5 ou moins.
- Si $D5$ est 16, alors 50% des données sont inférieures à 16.
- si $C95$ est 19, cela indique que 95% des données sont inférieures à 19.

Ces termes permettent une compréhension détaillée de la distribution des données



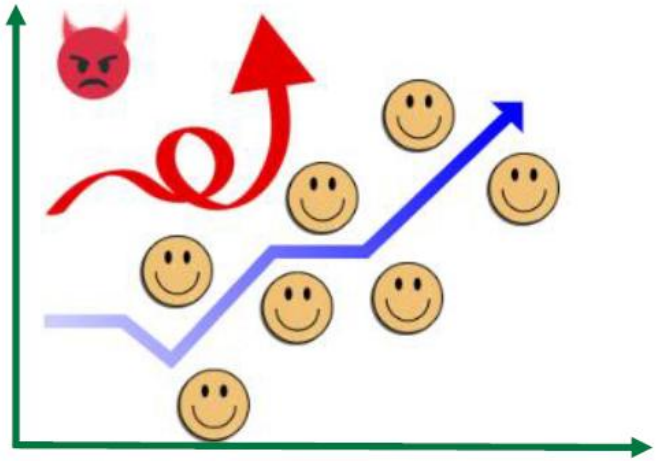
Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Analyse des Outliers : Introduction

En statistique ***Les valeurs aberrantes*** ou ***outliers*** en anglais, sont des points de données qui diffèrent significativement de la majorité des données dans un ensemble. Ce sont des observations qui se situent à une ***distance anormale*** par rapport aux autres valeurs, indiquant potentiellement un **événement rare** ou *une erreur de mesure.* Identifier et comprendre ces outliers revêt une importance cruciale dans l'analyse statistique, car ils peuvent exercer une influence sur les résultats et l'interprétation des analyses. Particulièrement dans des ensembles de données plus petits, leur influence peut être majeure.



Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Analyse des Outliers : Impact des valeurs aberrantes sur l'analyse et la modélisation des données

Les valeurs aberrantes peuvent avoir un impact significatif sur les résultats de l'analyse et de la modélisation des données. Elles peuvent fausser les mesures statistiques, conduisant à des estimations incorrectes de la tendance centrale et de la dispersion.

Exemple01 :

Si un ensemble de données sur les salaires des employés contient quelques salaires extrêmement élevés en raison de primes, le salaire moyen peut être considérablement surestimé, entraînant une moyenne salariale exagérée pour l'organisation.



Exemple 02 :

Si un ensemble de données sur les prix immobiliers contient quelques prix très bas en raison d'erreurs de saisie, le prix médian peut ne pas représenter avec précision le prix typique des maisons dans cette région.

Les outliers peuvent également affecter les performances des modèles de ML. Certains modèles, tels que la régression linéaire, sont sensibles aux outliers.

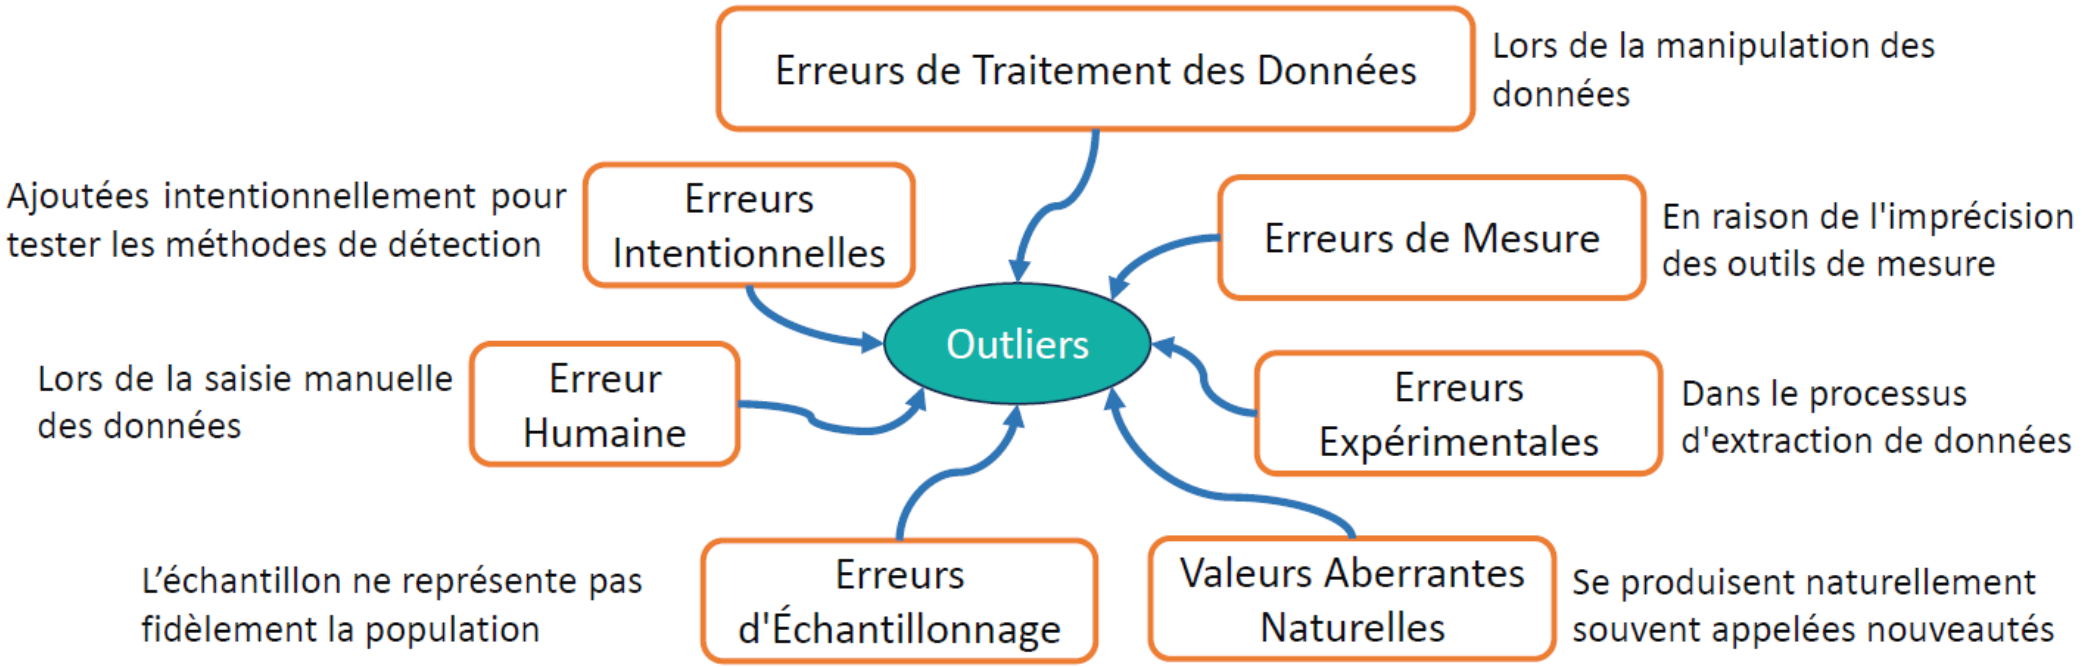
Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Analyse des Outliers : Causes des outliers ou valeurs aberrantes

Comprendre les causes des valeurs aberrantes aide grandement à les traiter, à prendre des décisions éclairées et à réduire leur occurrence lors des observations à venir.



Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Analyse des Outliers : Analyse et identification des Outliers

L'identification des valeurs aberrantes est un processus crucial dans l'analyse de données pour repérer les valeurs aberrantes. Dans ce cours, nous proposons trois méthodes principales :

- ***Mesures Statistiques*** : Utilisation des mesures telles que le minimum et le maximum.

- ***Visualisation*** : Emploi de graphiques tels que les box plots et même les tableaux d'Excel pour une identification visuelle.

- ***Techniques Statistiques Avancées*** : Mise en oeuvre de méthodes comme ***DBSCAN*** pour une identification précise.

Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Analyse des Outliers : Gestion et traitement des outliers

Explorez le processus de gestion des valeurs aberrantes dans l'analyse de données. Trois éléments clés guideront cette gestion :

- ***Stratégies de remplacement*** : Explorez des stratégies telles que le remplacement par des valeurs moyennes ou médianes pour des analyses plus robustes.

- ***Supprimer les outliers*** : Déterminez judicieusement quand supprimer les valeurs aberrantes de l'ensemble de données.

- ***Acceptez la présence d'outliers lorsque justifié*** : Discernez les situations où la présence d'outliers est pertinente et peut apporter des insights significatifs.

Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Mesures statistiques : Méthode des deux écarts-types (Two standard deviations method)

La méthode ***des deux écarts-types*** est une technique statistique qui identifie les valeurs aberrantes en considérant celles qui se situent en dehors de l'intervalle défini par ***la moyenne plus ou moins deux fois l'écart-type,*** dans le cadre d'une distribution normale. Elle repose sur l'idée que la plupart des données dans une distribution normale se trouvent dans l'intervalle de deux écarts-types de la moyenne, et donc, les valeurs en dehors de cet intervalle peuvent être considérées comme des valeurs aberrantes.

Le calcul se fait à l'aide de la fonction :

$$\text{Seuil} = \overline{X} \ (+ \text{ ou } -) \ 2\sigma$$

Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Mesures statistiques : Méthode des deux écarts-types (Two standard deviations method)

Application de la méthode : Example des revenus mensuels

- **Génération des données :**

Revenus mensuels : [4900, 4800, 5200, 5100, 4900, 4800, 5000, 15000, 4900, 4800, 1000, ...] (100 valeurs au total)

- **Calcul des mesures statistiques :**

Moyenne :

$$\bar{X} = \frac{\sum \text{Valeurs}}{\text{Nombre de Valeurs}}$$

$$\bar{X} = (4900+4800+5200+...+1000)/100 \Rightarrow \bar{X} = 4966$$

Écart-type :

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{\sum_{i=1}^{i}(Xi-\bar{X})^2}{n-1}}$$

$$\sigma = \sqrt{((4900-4966)^2 + (4800-4966)^2 + ... + (1000-4966)^2) / 99} \Rightarrow \sigma = 1407$$

Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Mesures statistiques : Méthode des deux écarts-types (Two standard deviations method)

Application de la méthode : Example des revenus mensuels

Identification des seuils supérieur et inférieur :

Seuil Supérieur : Ss = $\mathbf{X}$ + 2 σ

Seuil Supérieur= 4966 + 2 × 1407= 7781

Seuil Inférieur : Si = $\mathbf{X}$ - 2 σ

Seuil Inferieur= 4966 − 2 × 1407 = 2152

Identification des Outliers :

Les valeurs aberrantes « Outliers » sont celles qui sont au-dessus du seuil supérieur ou en dessous du seuil inférieur

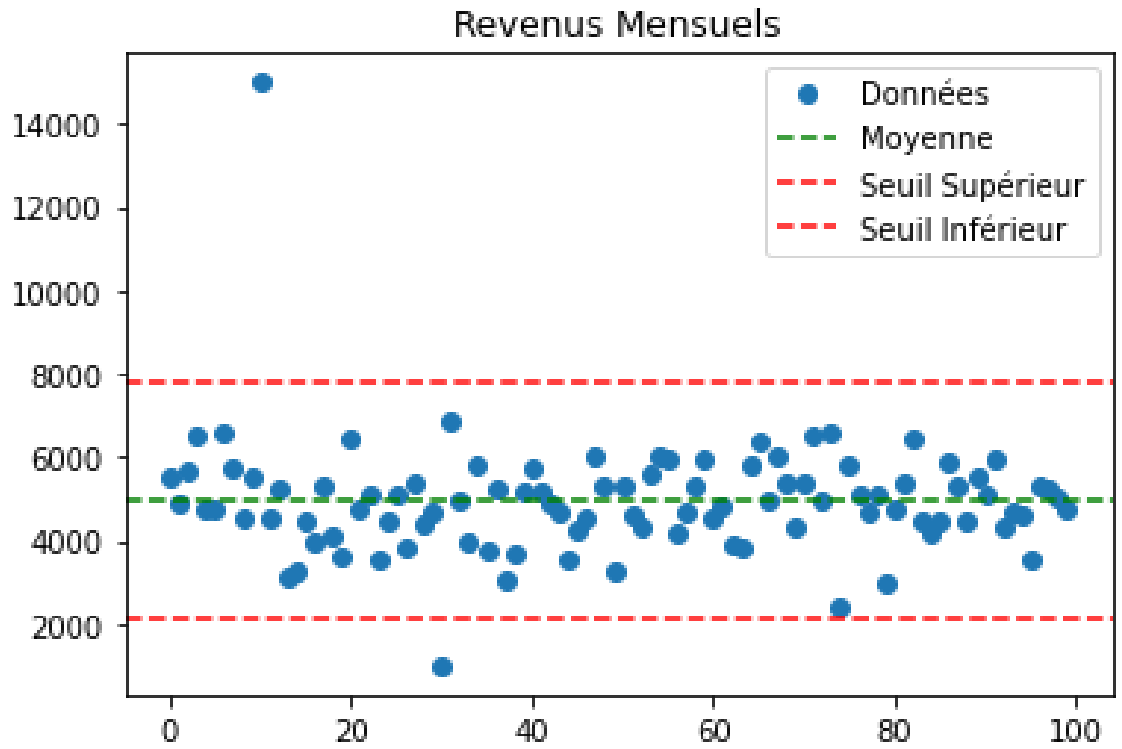
Affichage des résultats :

Revenus mensuels : [4900, 4800, 5200, 5100, 4900, 4800, 5000, 15000, 4900, 4800, 1000, ...]

Moyenne : 4966 | **Écart-type** : 1407

Seuil Supérieur : 7781 | **Seuil Inférieur** : 2152

Ex. Valeurs Aberrantes : [15000, 1000]



Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Mesures statistiques : Méthode des deux écarts-types (Two standard deviations method)

Identification des outliers : Example de calcul de la méthode des deux écarts-types avec Python

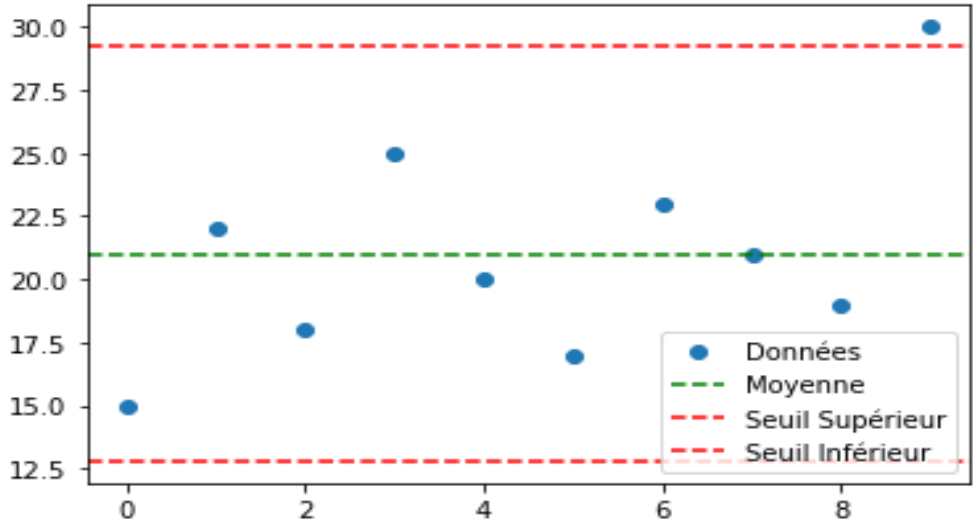
Génération des données :

Considérons un ensemble de données avec 10 valeurs :

```
import numpy as np
data = np.array([15, 22, 18, 25, 20, 17, 23, 21, 19, 30])
```

Calcul des mesures statistiques :

```
# Étape 1 : Calcul de la Moyenne et de l'Écart-type
mean = np.mean(data)
std_dev = np.std(data)
# Étape 2 : Définition des Seuils
threshold_upper = mean + 2 * std_dev
threshold_lower = mean - 2 * std_dev
# Étape 3 : Identification des Valeurs Aberrantes
outliers = [value for value in data if value > threshold_upper or
value < threshold_lower]
```




```
Données : [15 22 18 25 20 17 23 21 19 30]
Moyenne : 21.0 Écart-type : 4.09878030638384
Seuil supérieur : 29.19756061276768
Seuil inférieur : 12.80243938723232
Valeurs aberrantes : [30]
```

Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Mesures statistiques : Méthode des deux écarts-types (Two standard deviations method)

Identification des outliers : Example de calcul de la méthode des deux écarts-types avec Python

Reference d'affichage numériques :

```
print("Données :", data)
print("Moyenne :", mean)
print("Écart-type :", std_dev)
print("Seuil supérieur :", threshold_upper)
print("Seuil inférieur :", threshold_lower)
print("Valeurs aberrantes :", outliers)
```

Sortie Attendue :

```
Données : [15 22 18 25 20 17 23 21 19 30]
Moyenne : 21.0 Écart-type : 4.09878030638384
Seuil supérieur : 29.19756061276768
Seuil inférieur : 12.80243938723232
Valeurs aberrantes : [30]
```

Reference d'affichage graphique :

```
import matplotlib.pyplot as plt
# Visualisation des données avec seuils
plt.plot(data, 'o', label='Données')
plt.axhline(y=mean, color='g', linestyle='--', label='Moyenne')
plt.axhline(y=threshold_upper, color='r', linestyle='--', label='Seuil Supérieur')
plt.axhline(y=threshold_lower, color='r', linestyle='--', label='Seuil Inférieur')
plt.legend()
plt.show()
```

Sortie Attendue :

