Approfondir les Systèmes Décisionnels

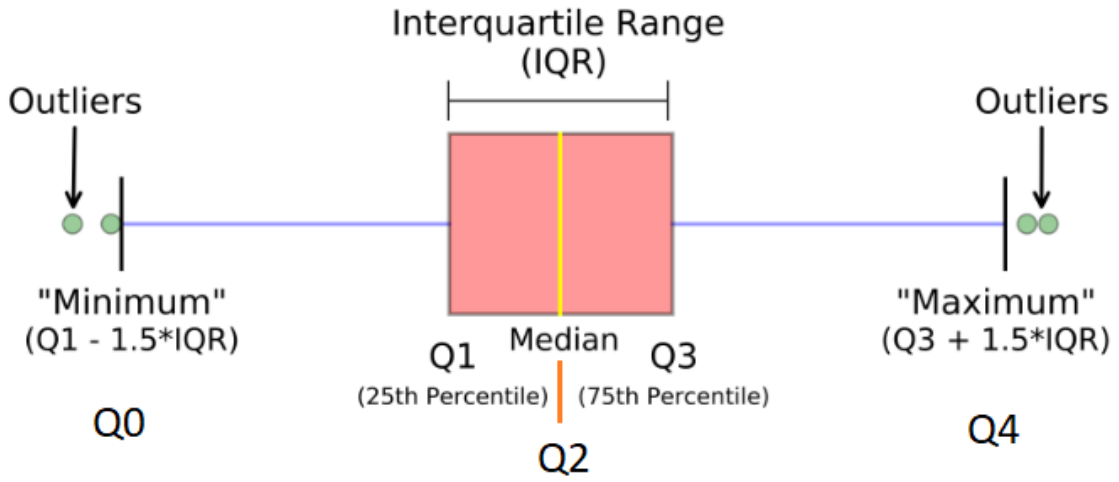
Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Mesures statistiques : ***Méthode IQR (Interquartile Range) : IQR = Q3-Q1***

L'intervalle interquartile (IQR) est une mesure statistique qui évalue la dispersion des données au sein d'un ensemble. Il est défini comme la différence entre ***le troisième quartile (Q3)*** et ***le premier quartile (Q1).*** Utilisé pour détecter les valeurs aberrantes, l'IQR identifie les points de données situées en dehors d'une plage définie par 1,5 (K) fois la longueur de l'IQR au-dessus du troisième quartile et en dessous du premier quartile. Cela permet de cibler les observations inhabituelles dans un ensemble de données.

Seuil inférieure = $\boldsymbol{Q1}$ - 1,5 × IQR



Seuil supérieure = $\boldsymbol{Q3}$ + 1,5 × IQR

Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Mesures statistiques : ***Méthode Tukey :***

L'utilisation de K = 3 au lieu de 1,5 signifie l'application de la méthode de Tukey, qui a tendance à éliminer moins de données.

Application de la méthode IQR :

Les Etapes à suivre :

1. Calculez le premier quartile (Q1) et le troisième quartile (Q3) de vos données.
2. Calculez l'écart interquartile (IQR) en soustrayant Q1 de Q3 : IQR = Q3 − Q1.
3. Définissez une limite inférieure comme Q1−1.5 × IQR et une limite supérieure comme Q3+1.5×IQR.
4. Toute valeur en dehors de ces limites est considérée comme une valeur aberrante.

Remarque :

Les valeurs couramment utilisées pour k sont 1.5 et 3, bien que d'autres valeurs puissent également utilisées en fonction des besoins.

Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Identification des outliers : ***Application de la méthode IQR et Tukey utilisent Python***

Pour détecter les Outliers dans un ensemble de données. la méthode statistique IQR évalue la dispersion des données en identifiant les points situées en dehors d'une plage définie par le premier et le troisième quartile, offrant une approche efficace pour cibler les observations inhabituelles

```python
import numpy as np
import matplotlib.pyplot as plt

# Exemple de données
data = np.array([2, 3, 4, 5, 6, 7, 20])

# Calcul de Q1, Q3 et IQR
q1 = np.percentile(data, 25)
q3 = np.percentile(data, 75)
iqr = q3 - q1

# Calcul des limites pour la méthode IQR
iqr_limite_inf = q1 - 1.5 * iqr
iqr_limite_sup = q3 + 1.5 * iqr

# Calcul des limites pour la méthode de Tukey
tukey_limite_inf = q1 - 3 * iqr
tukey_limite_sup = q3 + 3 * iqr
```

```python
# Identification des valeurs aberrantes
iqr_outliers = data[(data < iqr_limite_inf) | (data > iqr_limite_sup)]
tukey_outliers = data[(data < tukey_limite_inf) | (data > tukey_limite_sup)]
```

```python
# Affichage des valeurs calculées
print(f"Q1 : {q1}, Q3 : {q3}, IQR : {iqr}")
print(f"Limite inférieure IQR : {iqr_limite_inf}, Limite supérieure IQR :
{iqr_limite_sup}")
print(f"Limite inférieure Tukey : {tukey_limite_inf}, Limite supérieure
Tukey : {tukey_limite_sup}")
print(f"Valeurs aberrantes IQR : {iqr_outliers}")
print(f"Valeurs aberrantes Tukey : {tukey_outliers}")
```

Sortie Attendue :

```
Q1 : 3.5, Q3 : 6.5, IQR : 3.0
Limite inférieure IQR : -1.0, Limite supérieure IQR : 11.0
Limite inférieure Tukey : -5.5, Limite supérieure Tukey : 15.5
Valeurs aberrantes IQR : [20]
Valeurs aberrantes Tukey : [20]
```

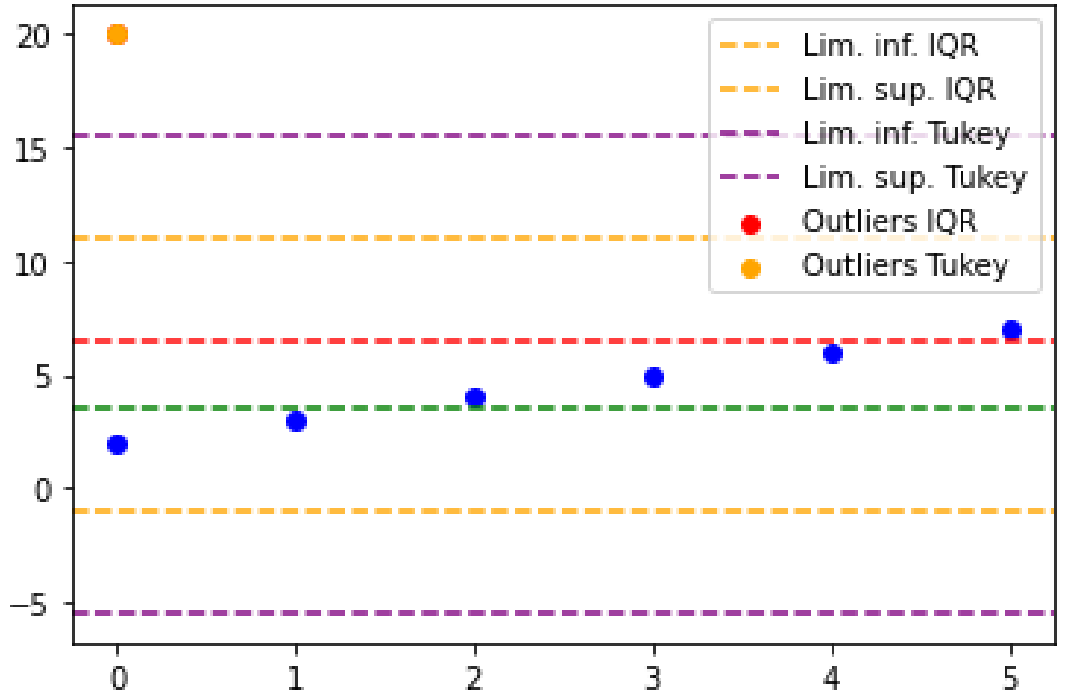
Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Identification des outliers : ***Visualisation des mesures IQR et Tukey utilisent Python***

Le graphique de visualisation présente les données initiales avec des points de données en bleu, les quartiles Q1 et Q3 en vert et rouge respectivement, ainsi que les limites définies par la méthode IQR et la méthode de Tukey. Les valeurs aberrantes détectées par chaque méthode sont marquées en rouge (IQR) ou orange (Tukey). Cette visualisation permet une compréhension rapide des points atypiques dans le jeu de données.



Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Identification des outliers : ***Visualisation des mesures IQR et Tukey utilisent Python***

Pour référence, nous présentons le code python nécessaire à la création de graphique précédente :

```
# Création d'un masque pour afficher uniquement les valeurs correctes
correct_data_mask = ~np.isin(data, iqr_outliers) & ~np.isin(data, tukey_outliers)

# Nuage de points avec uniquement les valeurs correctes
plt.scatter(range(len(data[correct_data_mask])), data[correct_data_mask], color='blue')#,
label='Points de données'
plt.axhline(y=q1, color='green', linestyle='--') #, label='Q1'
plt.axhline(y=q3, color='red', linestyle='--') #, label='Q3'
plt.axhline(y=iqr_limite_inf, color='orange', linestyle='--', label='Lim. inf. IQR')
plt.axhline(y=iqr_limite_sup, color='orange', linestyle='--', label='Lim. sup. IQR')
plt.axhline(y=tukey_limite_inf, color='purple', linestyle='--', label='Lim. inf. Tukey')
plt.axhline(y=tukey_limite_sup, color='purple', linestyle='--', label='Lim. sup. Tukey')
plt.scatter(range(len(iqr_outliers)), iqr_outliers, color='red', label='Outliers IQR')
plt.scatter(range(len(tukey_outliers)), tukey_outliers, color='orange', label='Outliers Tukey')

# Affichage du graphique
plt.legend()
plt.show()
```

Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Identification par visualisation: Box plot un outil efficace pour identifier les valeurs aberrantes

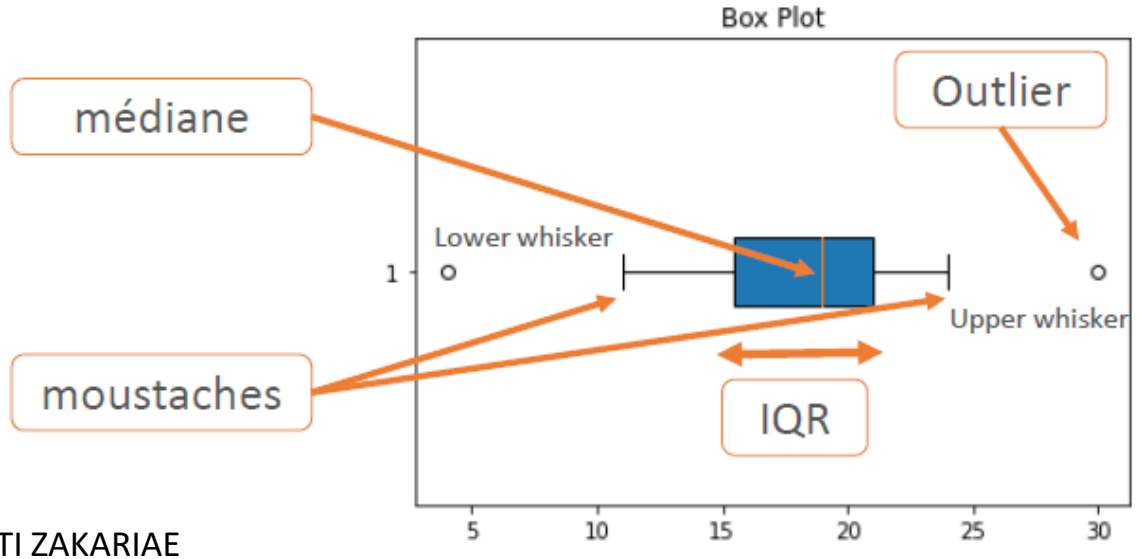
L'utilisation de graphiques, tels que les box plots et scatter plots, est une méthode puissante pour détecter visuellement les valeurs aberrantes. Les box plots présentent une représentation graphique des quartiles, de la médiane et des valeurs extrêmes, offrant une vue d'ensemble de la distribution des données.

Box Plots:

Les box plots permettent de repérer les valeurs aberrantes de manière intuitive. La boîte représente l'étendue interquartile IQR (Interquartile Range) entre le premier quartile (Q1) et le troisième quartile (Q3). Les lignes (moustaches) s'étendent jusqu'aux valeurs les plus éloignées qui ne sont pas considérées comme des valeurs aberrantes.

Interprétation des Box Plots :

Les box plots visualisent la distribution des données, montrant la médiane, les quartiles, et les valeurs minimale et maximale. Ils sont utiles pour comparer visuellement les ensembles de données. Les outliers sont représentés à l'extérieur des moustaches.



Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Identification par visualisation: Interprétation des Box Plots

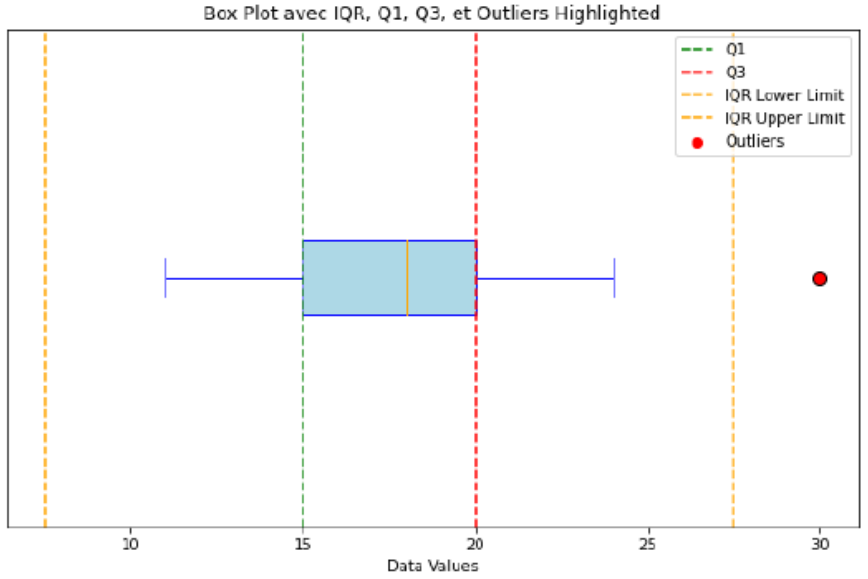
Lecture d'un Box Plot :

- Minimum et maximum alignés aux extrémités.
- Quartiles inférieur et supérieur alignés aux bords de la boîte.
- Médiane alignée avec la ligne intérieure de la boîte.

Analyse d'un Box Plot :

- Médiane plus grande indique une moyenne plus grande.
- Étendue = maximum – minimum. Une plus grande étendue signifie une dispersion plus importante.
- IQR = Q3 – Q1. Un IQR plus grand signifie une dispersion accrue pour la moitié centrale des données

Outliers par box plot :
Valeurs aberrantes **à l'extérieur** des moustaches.




```
Rappel IQR method :
iqr_lower_limit = q1 - 1.5 * iqr
iqr_upper_limit = q3 + 1.5 * iqr
```

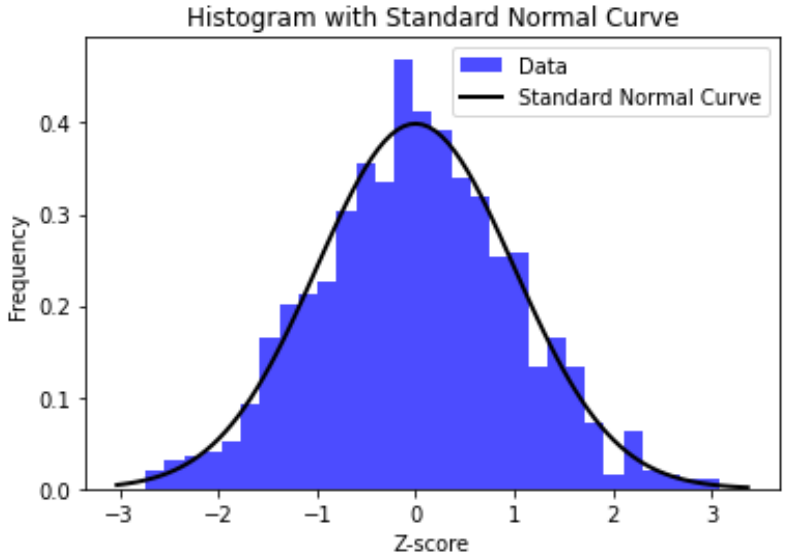
Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Techniques statistiques avancées : Z-Score (Standardization)

Le Z-score, ou standard score, est une mesure statistique qui quantifie de combien d'écarttypes un point de données se trouve par rapport à la moyenne d'un ensemble de données. Il est exprimé en tant que nombre d'écart-types par rapport à la moyenne, indiquant ainsi la position relative d'une observation ou d'un point de données particulier.



Formule Population : $Z = (x - \mu) / \sigma$

La formule pour calculer le Z-score d'un point de données ‘x' dans un ensemble de données avec une moyenne 'μ' et un écart-type ‘σ’.

Formule Échantillon : $Z = (x - \bar{X}) / s$

utilisée lorsqu'on travaille avec un échantillon plutôt qu'une population. Où $\bar{X}$ est la moyenne de l'échantillon et ‘s’ l'écart-type de l'échantillon.

Interprétation :

Un Z-score de 0 signifie que le point de données est à la moyenne, les Z-scores positifs et négatifs indiquent une position au-dessus ou en dessous de la moyenne. Ils identifient les valeurs aberrantes, permettent la comparaison entre distributions et définissent la position relative des données.

Approfondir les Systèmes Décisionnels

Approfondir les statistiques :

Maitriser les mesures de dispersion et de position :

Techniques statistiques avancées : Z-Score Example de compréhension

Exemple de Calcul dans un Échantillon :

Supposons un échantillon de données X={4,5,7,,}
Avec une moyenne d'échantillon $\mathbf{X}$=5
Un écart-type d'échantillon s=1.
Pour calculer le Z-score du point de données 7, utilisez la formule :

$$Z=(7 - 5) / 1 = 2$$

Les étapes restent les mêmes, mais la formule est ajustée pour refléter l'utilisation des statistiques d'échantillon.



Rappel :

Un échantillon est un ensemble d'individus représentatifs d'une population.